

UNIVERSITEIT TWENTE

Module 7 - 201400433

DISCRETE STRUCTUREN & EFFICIËNTE ALGORITMES

Preprocessing methoden

Het efficiënt maken van het Graaf Isomorfisme probleem

Projectgroep 1

Auteurs:

Joeri Kock
Remco Brunsveld
Frank Bruggink
Daniël Schut

Projectbegeleider:

Prof. Dr. J.C. van de Pol

April 10, 2015

Inhoudsopgave

1	Inleiding	2
2	Het Graaf Isomorfisme (GI) probleem	3
2.1	Relevantie van het GI probleem	3
2.2	Speciale gevallen	4
3	Het algoritme voor Color Refinement	5
4	Preprocessing	6
4.1	Methoden	6
4.1.1	Grootte	6
4.1.2	Connectiviteit	7
4.2	Validatie preprocessing methoden	8
5	Testen	9
6	Conclusie	10

1 Inleiding

Dit paper zal gaan over het Graaf Isomorfisme probleem, en hoe dit efficiënt gemaakt kan worden door middel van preprocessing. Het Graaf Isomorfisme probleem is een bekend probleem in de wiskunde en de informatica, wat het belangrijk maakt om dit op een zo snel mogelijke manier op te lossen. Als eerste wordt hierover (en over het algoritme wat wij hiervoor gebruiken) het een en ander uitgelegd. We zullen ook verschillende manieren van preprocessing bespreken, en toelichten waarom deze methoden geldig zijn binnen dit probleem. Daarna zullen we door middel van een experiment testen of deze methoden werken en wat het effect hiervan is op de snelheid en efficiëntie van ons algoritme. We sluiten dit document af met de conclusie.


We hebben in dit paper als hoofdvraag: “In hoeverre heeft het gebruik van preprocessing invloed op de tijdsduur van het vinden van isomorfe grafen met het Color Refinement-algoritme?”. We hopen natuurlijk dat het gebruik van preprocessing van positieve invloed is op de tijdsduur, d.w.z. dat het geheel minder lang duurt.

2 Het Graaf Isomorfisme (GI) probleem

Het Graaf Isomorfisme probleem is het probleem dat gaat over het vaststellen of twee grafen isomorf zijn, dat wil zeggen structureel gelijk aan elkaar. Als twee wiskundige objecten isomorf zijn, dan is elke eigenschap, waarvan de structuur bewaard blijft door een isomorfisme en die geldt voor een van de twee wiskundige objecten, ook geldig voor het andere wiskundige object.

Hoewel het op het eerste gezicht niet zo lijkt te zijn, geldt er een isomorfisme tussen de twee grafen hiernaast. Voor elke vertex van de eerste graaf geldt dat de buren daarvan exact hetzelfde zijn als de buren van diezelfde vertex in de tweede graaf.

Een methode om isomorfisme vast te kunnen stellen tussen deze twee grafen is color refinement. Dit algoritme kent kleuren toe aan de verschillende vertices, die een indicatie geeft welke buren deze vertex heeft. De groene vertex bijvoorbeeld heeft in de eerste graaf drie buren: de lichtblauwe, de roze en de gele. Dit geldt ook voor de tweede graaf. Als dit voor elke vertex in de twee grafen geldt, zijn ze isomorf. Dit kan als volgt gecontroleerd worden: wanneer de lijst met alle kleuren (zonder duplicaten) van de eerste graaf gelijk is aan die van de tweede graaf, kan er gezegd worden dat ze isomorf zijn ten opzichte van elkaar. In de afbeelding hierboven is dat ook het geval. Dit is een goede manier om isomorfisme te controleren, omdat het op het eerste gezicht bij deze afbeelding lijkt alsof de twee grafen niet isomorf zijn. Ook is deze methode nuttig bij grotere grafen met veel vertices.



Figuur 1: Twee isomorfe grafen

2.1 Relevantie van het GI probleem

Nu duidelijk gemaakt is wat het GI probleem inhoudt en hoe het gecontroleerd kan worden, blijft de vraag hoe relevant dit probleem is voor de Discrete Wiskunde. Waarom willen we weten of twee grafen (of zelfs wiskundige problemen in het algemeen) isomorf zijn ten opzichte van elkaar?

Isomorfisme heeft al voor het oplossen van vele wiskundige problemen gezorgd. Dat kan als volgt gedaan worden: een nog op te lossen wiskundig probleem X kan herleid worden tot een eenvoudiger probleem Y, wat makkelijker te begrijpen is. Neem een reeds opgelost probleem Z. Als aangetoond kan worden dat Y en Z isomorf zijn ten opzichte van elkaar, kan de conclusie getrokken worden

dat op dat moment probleem X ook opgelost is (omdat probleem X, Y en Z structureel hetzelfde zijn). In de Discrete Wiskunde zijn er al veel problemen met deze methode opgelost, wat het controleren op isomorfisme erg relevant maakt. Naast de wiskunde is het ook nuttig voor de informatica, omdat daar veel structuren als grafen weergegeven worden (denk aan netwerksystemen).

2.2 Speciale gevallen

Er zijn een aantal speciale gevallen waarvan bewezen is dat het in polynomiale tijd opgelost kan worden. Het eerste geval is een graaf die een boomstructuur heeft, dat wil zeggen: elk punt is met een ander punt verbonden, zonder cycli. De tweede zijn de planaire grafen, dat zijn de grafen die zo in het platte vlak getekend kunnen worden dat geen van de randen een andere rand kruist. Ook als je een restrictie legt op het aantal keren dat de randen elkaar minimaal kruisen, of als je een restrictie legt op de maximale graad van alle hoekpunten is het in polynomiale tijd op te lossen.

3 Het algoritme voor Color Refinement

Hier zullen we een korte uitleg geven over de implementatie van ons color refinement-algoritme.

Voordat we color refinement toepassen, geven we eerst elke vertex van de graaf een kleur die gelijk staat aan zijn degree. Het kleuren gebeurt niet in de graaf zelf, maar wordt apart bijgehouden door 2 arrays. De eerste array houdt voor elke kleur bij welke vertices die kleur hebben. De tweede array houdt voor elke vertex bij welke kleur hij heeft. Op deze manier hebben we de graaf zelf (bijna) niet meer nodig en kunnen we alle bewerkingen op de twee arrays uitvoeren, wat het proces sneller en overzichtelijker maakt.

Na de initiële kleuring voeren we color refinement uit over de lijsten. Als blijkt dat er nu geen duplicate kleuren meer zijn binnen elke graaf (d.w.z. binnen een graaf bestaan er geen twee vertices met dezelfde kleur) is het klaar en kunnen we controleren welke graven isomorf zijn. Zijn er wel duplicate kleuren, dan moet ‘individual refinement’ toegepast worden.

Individual refinement wordt alleen toegepast op de graven met duplicate kleuren. Het algoritme werkt als volgt: hij zoekt eerst een kleur op die bezet wordt door meerdere vertices. Vervolgens neemt hij één van deze vertices, en vervangt zijn kleur. Bij beide grafen wordt hiervoor een andere (nieuwe) kleur gekozen. Hierna wordt color refinement opnieuw toegepast. Als er nog steeds duplicate kleuren bestaan wordt color refinement nogmaals toegepast. Als er een isomorfisme aangetoond kan worden, wordt individual refinement over een ander koppel graven toegepast. Is er geen isomorfisme dan wordt de herkleuring van graaf 1 en graaf 2 teruggedraaid en wordt er een andere duplicate kleur van graaf 2 vervangen, waarna het algoritme zich weer herhaalt.

4 Preprocessing

Om het algoritme een handje te helpen bij het efficiënt oplossen van het GI probleem, kunnen er voor het color refinement-algoritme al stappen ondernomen worden, zodat het algoritme zelf minder tijd nodig heeft en dus het algoritme sneller en efficiënter wordt. Voor het algoritme kunnen er namelijk grafen geëlimineerd worden uit de lijst die niet in aanmerking komen om isomorf te zijn met een andere graaf uit de lijst. Als je van tevoren deze grafen uit de lijst haalt, hoeft het color refinement-algoritme minder grafen te behandelen, waardoor het efficiënter wordt.

Voor het testen gebruik je een lijst van grafen, bijvoorbeeld een lijst met 4 grafen. Als er één graaf is in de lijst die een van de eigenschappen van het preprocessing niet heeft en de andere drie wel, kan deze graaf uit de lijst gehaald worden. Het is dan namelijk niet meer mogelijk dat deze graaf isomorf is met één van de andere grafen. Maar als twee grafen de eigenschappen wel hebben en twee niet, zetten we deze paren van grafen in twee aparte lijsten, waar vervolgens het color refinement-algoritme op uitgevoerd kan worden.

4.1 Methoden

We controleren de grafen van tevoren op de volgende eigenschappen:

4.1.1 Grootte

De grootte van de graaf, d.w.z. het aantal vertices en het aantal edges. Als er in de lijst n graaf is met een ander aantal vertices of edges dan de andere grafen, kan deze graaf uit de lijst gehaald worden. Hij kan dan niet meer isomorf zijn met een andere graaf. De pseudo-code voor het testen op grootte staat hieronder:

Data: Een lijst van grafen

Result: Een lijst van grafen die mogelijk isomorf zijn

resultaat = lege lijst

```
for Elke graaf i in de lijst do
  for Elke andere graaf j in de lijst do
    if Het aantal vertices van graaf i en j zijn gelijk then
      if Het aantal edges van graaf i en j zijn gelijk then
        | Voeg i en j toe aan het resultaat
      end
    end
  end
end
return resultaat
```

4.1.2 Connectiviteit

Als een graaf als enige in de lijst niet connected is (en de andere grafen dus wel), kan deze ook geëlimineerd worden. Met een combinatie van deze eerste twee eigenschappen wordt ook gelijk gecontroleerd op het feit of een graaf een boom is of niet. Als twee connected grafen een gelijk aantal vertices en edges hebben, zijn ze namelijk beide een boom of beide niet. Hier hoeft dus niet meer op gecontroleerd te worden. De pseudo-code voor het testen op connectiviteit staat hieronder:

```
Data: Een lijst van grafen  
Result: Een lijst van grafen die mogelijk isomorf zijn  
resultaat = lege lijst  
for Elke graaf i in de lijst do  
    for Elke andere graaf j in de lijst do  
        if Grafen i en j zijn beide connected then  
            | Voeg i en j toe aan het resultaat  
        end  
    end  
end  
return resultaat
```

In de If-statement staat dat we controleren of beide grafen i en j connected zijn. Hier is geen standaard functie voor beschikbaar, dus we hebben zelf een algoritme geschreven (dat je op een graaf kunt uitroepen) dat teruggeeft of een graaf connected is of niet. De pseudo-code hiervan staat hieronder beschreven:

```
Data: De graaf zelf  
Result: True als hij connected is, anders False  
x = een willekeurige vertex  
L = een lijst van vertices bereikbaar vanaf x  
K = een lijst van vertices die nog ontdekt moeten worden  
Aan het begin van het algoritme geldt  $L = K = x$   
while K is niet leeg do  
    | Vind een vertex y in K en haal deze eruit  
    for elke edge (y,z) do  
        | if z zit niet in L then  
            | | Voeg z toe aan L en K  
        end  
    end  
end  
if L heeft minder dan n elementen then  
    | return False  
else  
    | return True  
end
```


4.2 Validatie preprocessing methoden

Een isomorfisme is een bijectieve afbeelding $f : V(G) \rightarrow V(H)$ zodanig dat $\forall u, v \in V(G)$ er geldt dat $uv \in E(G) \Leftrightarrow f(u)f(v) \in E(H)$.

We hebben 3 preprocessing stappen gemaakt.

1. Als $|V(G)| \neq |V(H)|$ dan kan er geen isomorfisme bestaan.
2. Als $|E(G)| \neq |E(H)|$ dan kan er geen isomorfisme bestaan.
3. Als een graaf wel ‘connected’ is en de andere niet, dan kan er geen isomorfisme bestaan.

Nu volgt het bewijs dat twee grafen niet isomorf zijn als aan een van de volgende 3 voorwaarden wordt voldaan:

1. Als $|V(G)| \neq |V(H)|$ dan kan je geen bijectie definiëren, want een bijectie moet one-to-one zijn, en daarvoor moeten beide sets evenveel elementen bevatten.
2. Als $|E(G)| \neq |E(H)|$ dan is er een tegenspraak met de eis dat $uv \in E(G) \Leftrightarrow f(u)f(v) \in E(H)$.
3. Neem aan dat H connected is en G niet. Zonder verlies van algemeenheid kunnen we aannemen dat G bestaat uit twee delen die beide connected zijn, noem ze G_1 en G_2 .

Neem nu aan dat er een isomorfisme tussen G en H bestaat. Deel H op in twee delen, H_1 en H_2 , zodanig dat $\forall g_1 \in V(G_1)$ geldt dat $f(g_1) \in V(H_1)$ en $\forall g_2 \in V(G_2)$ geldt dat $f(g_2) \in V(H_2)$. Dan $\exists g_1 \in G_1$ en $g_2 \in G_2$ zodanig dat $g_1g_2 \in E(G)$, terwijl $f(g_1)f(g_2) \notin E(H)$. Dit levert een tegenspraak op.


Dus de grafen moeten beide wel of beide niet connected zijn.

5 Testen

We hebben onze code uitvoerig getest op verschillende delen. Als eerste hebben we testklassen gemaakt in Python die uitgevoerd kunnen worden en (met behulp van wat randgevallen) testen of onze preprocessing-methoden naar behoren werken. Dit zijn zogenaamde ‘unittests’ die als volgt werken: we testen eerst of onze functie `isConnected` werkt. Dit doen we door deze functie uit te voeren op vier grafen, waarvan er één niet connected is. Hier voeren we dus een drietal `assertTrue`- en één `assertFalse`-functie(s) op uit.

Bovendien kijken we of het aanpassen van de lijsten werkt. Immers, als er één graaf als enige niet connected is of een ander aantal vertices of edges heeft, moet deze uit de lijst gehaald worden. We voeren hiervoor de betreffende methoden uit, en we controleren naderhand of de aangepaste lijst overeenkomt met de lijst die we voorspeld hadden.

We hebben naast de werking ook het effect van onze algoritmes getest. Met behulp van verschillende lijsten van grafen (waaronder we er een aantal zelf geschreven hebben) hebben we experimenten uitgevoerd waar we hebben gekeken of de preprocessing-methoden ook daadwerkelijk effect hadden op de tijd die het algoritme erover doet. Het resultaat van dit experiment is te zien in de grafiek hieronder.



De waarden in de grafiek staan voor hoeveel sneller of langzamer het algoritme er procentueel over doet t.o.v. zonder de preprocessing. Wat erg duidelijk te zien is, is dat als we één graaf een ander aantal vertices geven, we een significante verbetering zien wanneer we hierop controleren d.m.v. preprocessing. Dit is bij de connectiviteit ook het geval. Wanneer de grafen al isomorf zijn, heeft het natuurlijk enkel een negatief effect. Je voert namelijk extra controles uit op eigenschappen waarvan je weet dat dit niet hoeft, aangezien de grafen al isomorf zijn.

6 Conclusie

Op basis van de gemeten testresultaten kunnen we een conclusie trekken over de gebruikte methoden van preprocessing. Dat is dat ze wel degelijk verschil maken in de uiteindelijke tijd, mits het ook noodzakelijk is deze controles uit te voeren. Als er in de lijst een graaf is die als enige connected is, wordt deze uit de lijst gehaald. Dit scheelt het Color Refinement-algoritme erg veel tijd. Heb je echter een lijst van grafen die allemaal evenveel vertices en edges hebben en allemaal connected of niet connected zijn, kost het algoritme een (klein) beetje extra tijd, omdat je controles uitvoert die niet nodig zijn.

Referenties

- [1] Gaurav Rattan Oleg Verbitsky V. Arvind, Johannes Kbler, *Graph isomorphism, color refinement, and compactness*, 2015.
- [2] N. M.; Tyshkevich R. I. Zemlyachenko, V. N.; Korneenko, *Graph isomorphism problem*, 1985.